Brain MRI Segmentation with nnU-Net — Proje Raporu

1. Proje Başlığı

Beyin MR Görüntülerinde Alt Dereceli Gliom (LGG) Segmentasyonu: nnU-Net Prensipleriyle Geliştirilmiş 2D U-Net

Hazırlayan: Umut Türkmen · **Kod (Notebook):** GitHub bağlantısı eklenecek

Özet: 110 LGG hastasına ait 3.929 MR kesiti üzerinde, her pikseli tümör / sağlıklı doku olarak sınıflandıran uçtan uca bir semantic segmentation modeli geliştirildi. nnU-Net ön işleme ve optimizasyon prensipleriyle güçlendirilmiş bir 2D U-Net, 25 epoch eğitildi. Model, eğitimde hiç görmediği 17 hastalık test setinde **%87,85 Precision**, **%80,64 Recall**, **0,8409 F1 (Dice)** ve **0,7255 IoU** değerlerine ulaştı.

2. Problem Tanımı

Alt Dereceli Gliomlar (Lower-Grade Gliomas, LGG), glial hücrelerden kaynaklanan, yavaş büyüyen ancak sağlıklı beyin dokusuna sızma eğilimi gösteren beyin tümörleridir. Tümör sınırlarının MR görüntülerinde doğru belirlenmesi; cerrahi, radyoterapi planlaması ve hasta takibi için kritiktir. Ancak bu sınırların çok sayıda kesitte elle çizilmesi hem zaman alıcıdır hem de uzmanlar arası farklılıklara (inter-observer variability) açıktır.

Projenin amacı; 256×256×3 boyutlu 2D beyin MR kesitini girdi olarak alıp her pikseli **"0: Sağlıklı doku / Arka plan"** veya **"1: Tümör / FLAIR anomalisi"** olarak etiketleyen ve çıktı olarak 256×256×1 binary mask üreten bir semantic segmentation modeli geliştirmektir.

3. Veri Seti

Veri seti, The Cancer Imaging Archive (TCIA) ve The Cancer Genome Atlas (TCGA) LGG koleksiyonlarından derlenmiş olup Kaggle üzerinden açık kaynak olarak alınmıştır (Mateusz Buda vd., LGG MRI Segmentation).

Bağlantı: https://www.kaggle.com/datasets/mateuszbuda/lgg-mri-segmentation/

Veri seti **110 hastaya ait 3.929 MR kesiti** (256×256×3) ve bunlara karşılık gelen uzman onaylı binary maskelerden (256×256×1; 0: arka plan, 1: tümör) oluşur. Üç kanal sırasıyla Pre-contrast, FLAIR ve Post-contrast MR sekanslarıdır. 9 hastada post-contrast, 6 hastada pre-contrast sekansı eksiktir; bu kanallar tümörü en net gösteren FLAIR sekansı kopyalanarak doldurulmuştur.

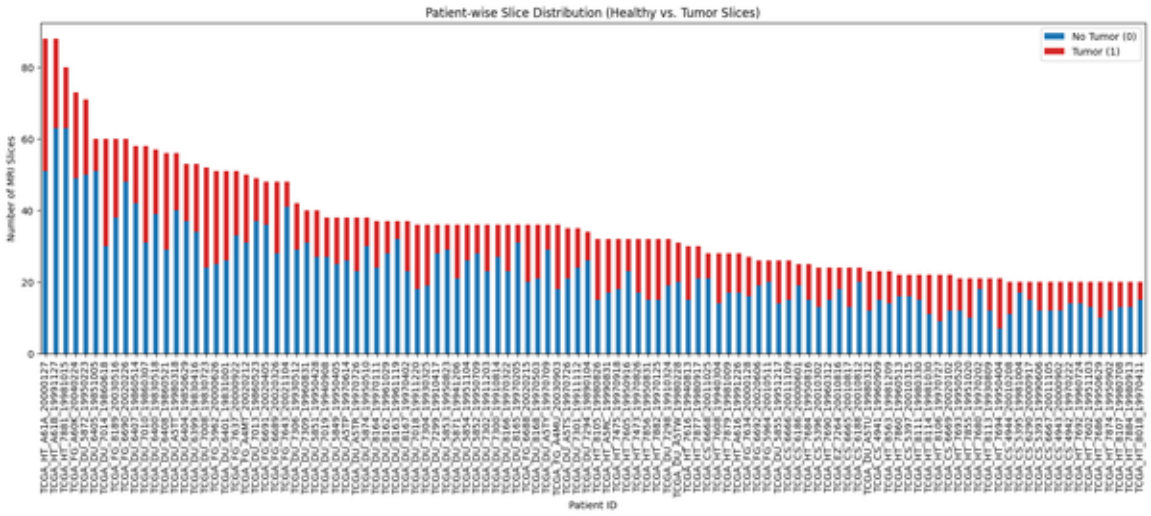
Sınıf dengesizliği iki seviyededir: kesitlerin 2.556'sı (%65,1) tümörsüz, yalnızca 1.373'ü (%34,9) tümörlüdür (kesit seviyesi); tümörlü kesitlerde bile tümör pikselleri görüntünün çok küçük bir bölümüdür (piksel seviyesi).

4. Veri Analizi ve Ön İşleme

4.1 Veri Keşfi (EDA)

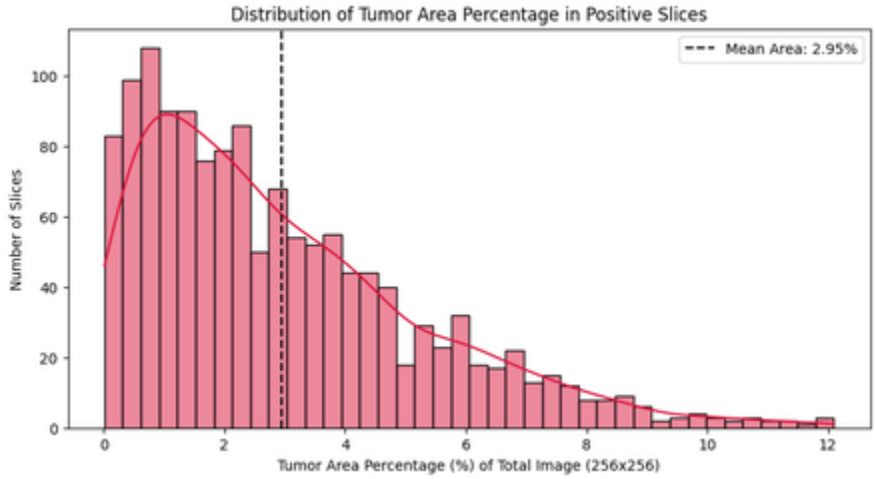
Veri tablosunda (3.929 satır) eksik değer bulunmamaktadır. Veri üzerinde üç temel inceleme yapılmıştır.

a) Hasta bazlı kesit dağılımı (Şekil 1): Hasta başına kesit sayısı 20 ile 88 arasında değişir; çünkü veri farklı kurumlardan (TCGA_HT, TCGA_DU, TCGA_FG, TCGA_CS) farklı kesit kalınlığı protokolleriyle toplanmıştır. Aynı hastanın ardışık kesitleri birbirine çok benzediğinden veri bölme **hasta bazlı** yapılmıştır.



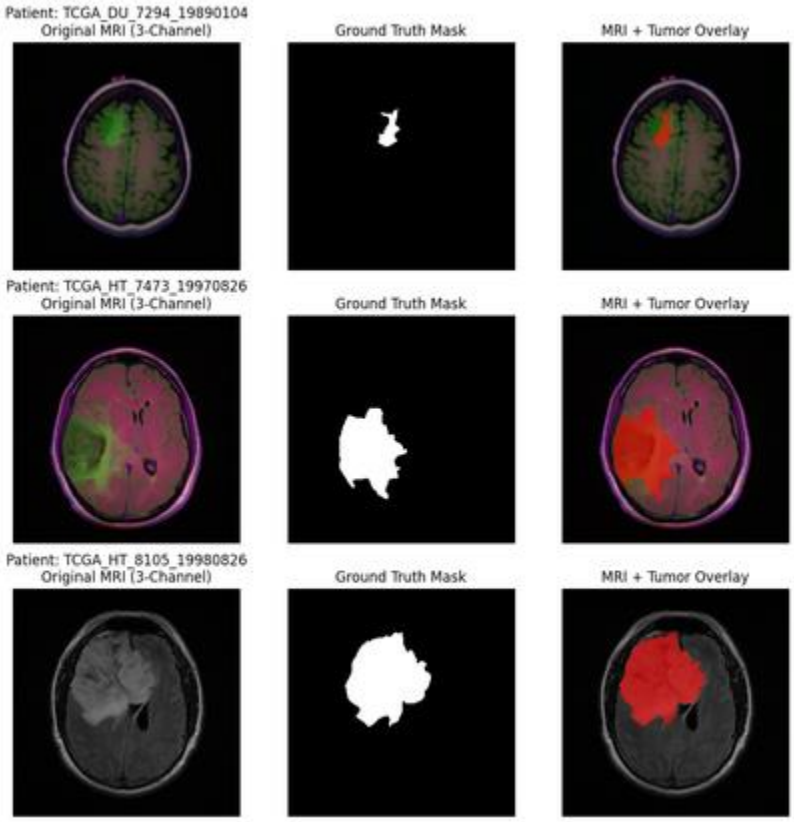
Şekil 1: Hasta başına tümörsüz (mavi) ve tümörlü (kırmızı) kesit sayıları.

b) Tümör alanı yüzdesi (Şekil 2): Tümörlü kesitlerde bile tümör, görüntünün ortalama yalnızca **%2,95**'ini kaplar. Dağılım sağa çarpıktır; çoğu kesitte alan %0,5–%2,0 aralığındadır ve en büyük tümör bile ~%12'yi aşmaz. Bu durumda her piksele "0" diyen bir model bile ~%97 accuracy alır. Bu nedenle başarı **Dice (F1)** ve **IoU** ile ölçülmüş, eğitimde **BCE + Soft Dice** loss kullanılmıştır.



Şekil 2: Tümörlü kesitlerde tümör alanının görüntüye oranı.

c) MR, maske ve overlay (Şekil 3): İlk iki örnekte tümör yeşil tonlarda belirgindir; çünkü FLAIR sekansı yeşil (G) kanala atanmıştır. Üçüncü örnek (TCGA_HT_8105) ise R = G = B = FLAIR olduğu için gri tonludur; bu tutarsızlık kesit bazında normalizasyonu gerekli kılar. Ayrıca lezyon boyutları çok farklıdır; küçük ve büyük yapıları birlikte yakalamak için skip connection'lı U-Net seçilmiştir.



Şekil 3: Örnek MR kesiti, ground truth mask ve tümör overlay.

4.2 Veri Ön İşleme

- **Hasta bazlı bölme (%70 / %15 / %15):** Train 77 hasta (2.801 kesit), validation 16 hasta (567 kesit), test 17 hasta (561 kesit). Kümeler arasında ortak hasta yoktur; data leakage engellenmiştir.
- **Data augmentation (yalnızca train):** Albumentations ile %50 olasılıkla yatay/dikey çevirme ve ±15° döndürme; görüntü ve maskeye birlikte uygulanır.
- **nnU-Net Z-score normalizasyonu:** MR yoğunluklarının sabit bir birimi olmadığından her kesitin her kanalı kendi ortalaması ve standart sapmasıyla standartlaştırılır: $I_{norm} = (I - \mu) / (\sigma + 10^{-8})$.
- **Maske:** 0/1 değerlerine çevrilir. Batch boyutu görüntü için [16, 3, 256, 256], maske için [16, 1, 256, 256]'dır.

5. Model / Yöntem

Klasik sınıflandırma CNN'leri, son katmanlardaki dense yapılar nedeniyle uzamsal konum bilgisini kaybeder. Piksel seviyesinde segmentation için bu nedenle simetrik encoder-decoder yapısına sahip **U-Net** seçilmiştir. Encoder, MaxPool2d ile çözünürlüğü yarıya indirip kanal sayısını artırarak global bağlamı

(“ne var?”) yakalar. Decoder, ConvTranspose2d ile 256×256 çözünürlüğü geri kazanır (“nerede?”). Skip connection’lar ise encoder özelliklerini decoder’a aktararak ince tümör sınırı detaylarını korur.

Aşama	Katman	Kanal	Çözünürlük
Encoder 1–4	DoubleConv (+ MaxPool)	3 → 64 → 128 → 256 → 512	256 → 32
Bottleneck	MaxPool + DoubleConv	512 → 1024	16×16
Decoder 4–1	ConvTranspose2d + skip + DoubleConv	1024 → 64	32 → 256
Çıkış	Conv2d (1×1)	64 → 1 (logit)	256×256

DoubleConv bloğu: İki kez Conv2d (3×3, padding = 1, bias = False) → BatchNorm2d → LeakyReLU. Z-score sonrası girdiler negatif değerler içerdiğinden ReLU yerine **LeakyReLU (0,01)** kullanılmıştır. Çıkışta sigmoid yoktur; sigmoid, sayısal kararlılık için `BCEWithLogitsLoss` içinde uygulanır.

Loss fonksiyonu: Tek başına BCE kullanıldığında arka plan pikselleri gradyanları domine eder. nnU-Net yaklaşımına uygun olarak **BCEDiceLoss = BCE + Soft Dice Loss** kullanılmıştır. BCE kararlı piksel bazında gradyan sağlar; Soft Dice ise tahmin ile gerçek maske arasındaki örtüşmeyi doğrudan optimize eder ve arka plan boyutundan etkilenmez.

Optimizer ve metrikler: AdamW (learning rate = 1e-4, weight decay = 1e-4) ile ReduceLROnPlateau scheduler (validation loss 3 epoch iyileşmezse learning rate yarıya iner) kullanılmıştır. Olasılıklar p > 0,5 eşiğiyle maskeye çevrilir; başarı Dice ve IoU ile izlenir.

6. Eğitim / Uygulama Süreci

Model PyTorch ile Google Colab üzerinde CUDA GPU kullanılarak eğitilmiştir. Her epoch’ta 2.801 train kesitiyle eğitim, ardından 567 validation kesitiyle değerlendirme yapılmıştır. Validation sırasında gradyan takibi kapatılmış (`torch.no_grad()`), model ağırlıkları yalnızca yeni bir en yüksek validation Dice skorunda kaydedilmiştir (checkpointing). En iyi model (`best_unet_model.pth`) ve eğitim geçmişi (`history.json`) Google Drive’a kaydedilerek tekrarlanabilirlik sağlanmıştır.

Hiperparametre	Değer
Epoch / Batch size	25 / 16
Optimizer	AdamW (lr = 1e-4, weight decay = 1e-4)
Scheduler	ReduceLROnPlateau (factor = 0,5, patience = 3)
Loss	BCE + Soft Dice
Karar eşiği	p > 0,5

7. Değerlendirme Sonuçları

7.1 Eğitim ve Validation Eğrileri



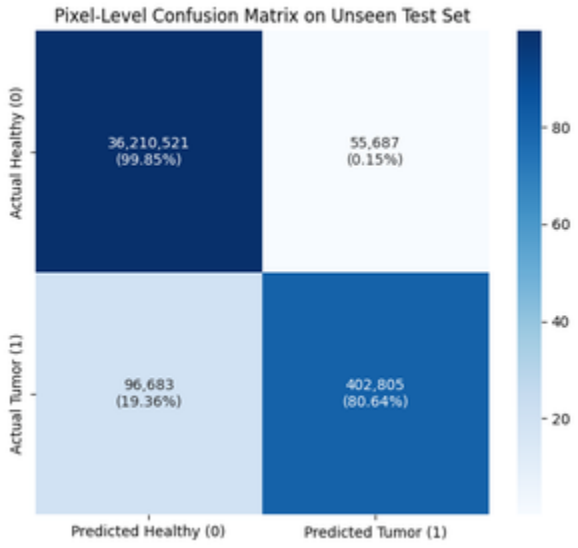
Şekil 4: 25 epoch boyunca loss, Dice ve IoU değerlerinin değişimi (mavi: train, kırmızı: validation).

- **İlk 9 epoch:** Train ve validation loss birlikte 1,30'dan 0,50 seviyesine düşmüştür; erken dönemde overfitting görülmemektedir.
- **Epoch 10–25:** ReduceLROnPlateau scheduler validation eğrisini stabilize etmiştir. Model en iyi performansına **Epoch 24**'te ulaşmıştır: **Validation Dice ≈ 0,82** ve **Validation IoU ≈ 0,72** (Train Dice ≈ 0,88).
- **Generalization gap:** Train ve validation Dice arasındaki ~%6'lık fark, validation setindeki hastalar ve kurumlar arası MR çekim farklılıklarını yansıtmaktadır.

7.2 Test Seti Sonuçları

En iyi model, eğitimde hiç kullanılmayan test setinde (17 hasta, 561 kesit, 36.765.696 piksel) piksel bazında değerlendirilmiştir. %99,59 accuracy, piksellerin büyük çoğunluğu arka plan olduğu için yanıltıcıdır; asıl başarıyı **Precision, Recall, F1 ve IoU** gösterir.

Test sonuçları: Precision **0,8785** · Recall **0,8064** · F1 (Dice) **0,8409** · IoU **0,7255** · Accuracy **0,9959**

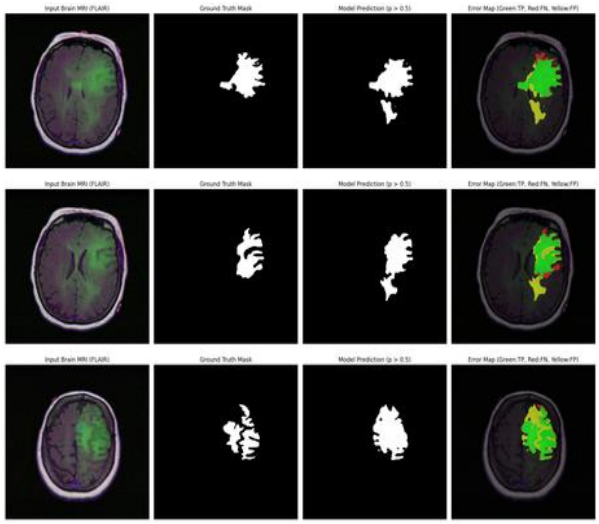


Şekil 5: Test setinde piksel seviyesinde confusion matrix (yüzdeler satır bazında).

Confusion matrix'e göre model 402.805 tümör pikselini doğru bulmuş (TP), 96.683 pikseli kaçırmış (FN, %19,36), sağlıklı piksellerin ise yalnızca 55.687'sini (%0,15) yanlışlıkla tümör olarak işaretlemiştir (FP). Precision'ın (%87,85) Recall'dan (%80,64) yüksek olması, modelin yanlış alarm üretmekten çok tümör piksellerini kaçırma eğiliminde olduğunu gösterir.

8. Hata Analizi

Şekil 6'da test setinden tümörlü kesitler; girdi MR, ground truth, model tahmini ve error map ile gösterilmiştir. **Yeşil (TP)** doğru bulunan tümör çekirdeğini, **kırmızı (FN)** kaçırılan pikselleri, **sarı (FP)** ise fazla segment edilen bölgeleri gösterir.



Şekil 6: Test setinden örnek tahminler. Error map: Yeşil = TP, Kırmızı = FN, Sarı = FP.

Hataların olası nedenleri: Test piksellerinin %98,64'ünün sağlıklı doku olması (72:1 dengesizlik), modelde hafif temkinli bir eğilim oluşturur. LGG'lerin belirsiz, infiltratif sınırlarında ve düşük hacimli geçiş kesitlerinde modelin güveni sabit 0,5 eşiğinin hemen altında kalır; FN'lerin ana nedeni budur. FP'ler ise dallı lezyonlardaki dar sulkal boşlukların doldurulmasından ve çevredeki hiperintens ödeme taşmadan kaynaklanır. Ayrıca kesitler bağımsız 2D görüntüler olarak işlendiğinden ardışık kesitler arasındaki 3D süreklilik kullanılamamaktadır.

9. Sonuç ve Geliştirme Önerileri

Güçlü ve zayıf yönler: Hasta bazlı bölme sayesinde model tamamen görülmemiş hastalarda test edilmiş, yani metrikler gerçek genelleme başarısını yansıtır. Z-score normalizasyonu, LeakyReLU ve BCE + Soft Dice loss arka plan baskınlığını engellemiş ve False Positive oranını %0,15'te tutmuştur. Zayıf yönler ise sınırlardaki piksel kaybı (FN %19,36), sulkal yumuşatma ve 2D yaklaşım nedeniyle 3D bağlamın kullanılamamasıdır.

Geliştirme önerileri: Ardışık kesitleri (z−1, z, z+1) çok kanallı girdi olarak veren bir 2.5D yapı veya 3D U-Net ile kesitler arası süreklilik yakalanabilir. Sınır hataları için Surface/Boundary Loss eklenebilir, karar eşiği validation Precision-Recall eğrisiyle ayarlanabilir (ör. $p \approx 0{,}40$) ve Connected Component Analysis (CCA) ile post-processing uygulanabilir. Son olarak Test-Time Augmentation (TTA) ile çevrilmiş görüntülerin tahminlerinin ortalaması alınarak sınırlardaki güven artırılabilir.